

大数据计算基础

BIG DATA COMPUTING

刘显敏 海量数据
liuxianmin@hit.edu.cn

大数据算法

2025年秋

2

亚线性时间算法

Sublinear Time Algorithm

3

亚线性时间算法

高效算法的标准是什么？

- 多项式时间算法
- 线性时间算法：输入大小为 n ，算法的时间代价是 cn

若时间资源受限，甚至不允许读数据一遍，能做什么？

- 无法回答“for all”或者“exactly”类似的问题
 - 数组中是否所有元素均比10大？数组中比10大的有多少？
- 或许能够回答下列问题
 - 数组中比10大的元素大概有多少？
 - 数组中的平均数是否以很大概率大于10？

算法的计算目标需要修改

4

亚线性时间算法

算法的计算目标需要修改

- 对于绝大多数问题，我们只能给出近似的答案什么是“近似”
- 经典的近似算法概念：
 - 算法的结果有一个度量函数：路径长度
 - 算法结果度量值与最优解度量值“接近”：近似比
- Property Testing（判定问题）
 - 算法的结果是yes或者no
 - 算法输出要么与输入 I 对应的答案相同，要么与 I' 对应的答案相同，这里 I' 与 I 非常接近

5

问题1：点集合的直径

点集合的直径问题

输入： m 个点，距离用矩阵 D 表示

- (1) D_{ij} 是点到点的距离
- (2) D 是对称的，并且满足三角不等式

$$D_{ij} \leq D_{ik} + D_{kj}$$

输出：(i, j)使得 D_{ij} 是最大的， D_{ij} 是点集合的直径

6

问题1：点集合的直径

亚线性求解直径算法 (Indyk's Algorithm)

```
/** input D ***/
1. 选取任意一个 k, 选取 l 最大化  $D_{kl}$ ;
2. return (k, l)
```

近似比分析： $opt/2 \leq D_{kl} \leq opt$

$$\begin{aligned} opt &= D_{ij} \leq D_{ik} + D_{kj} \quad (\text{三角不等式}) \\ &\leq D_{kl} + D_{kl} \quad (\text{l是最大化选择}) \\ &\leq 2D_{kl} \end{aligned}$$

运行时间： $O(m) = O(\sqrt{n})$

问题2：连通分量的数目

7

连通分量的数目 (#CC)

输入： $G = (V, E)$, $c, d = \deg(G)$

图G用邻接链表表示, $|V| = n$, $|E| = m \leq dn$

输出： y , 令 $C = \#CC$

$C - \epsilon n \leq y \leq C + \epsilon n$ (additive appro.)

#CC可以在线性时间求解 (DFS或者BFS)

问题2：连通分量的数目

8

n_v : 顶点 v 所属的连接分量中的节点数目

$A: A \subseteq V$ 是一个连通分量的点集合

$$\sum_{u \in A} \frac{1}{n_u} = \sum_{u \in A} \frac{1}{|A|} = 1$$

$$C = \#CC = \sum_{u \in V} \frac{1}{n_u}$$

为什么用这种表示?

- ▶ 可以支持高效估计(estimate)

问题2：连通分量的数目

9

$$\text{估计 } C = \sum_{u \in V} \frac{1}{n_u} : \text{ 估计 } \frac{1}{n_u} \Rightarrow \text{估计 } \sum_{u \in V} \frac{1}{n_u}$$

估计 $\frac{1}{n_u}$

想法: n_u 很大, 精确计算很难, 但此时 $\frac{1}{n_u}$ 很小, 可以用一个很小的常量代替 $\frac{1}{n_u}$ (0或者 $\epsilon/2$)

$$\hat{n}_u = \min \left\{ n_u, \frac{2}{\epsilon} \right\} \quad \hat{C} = \sum_{u \in V} \frac{1}{\hat{n}_u}$$

引理: $\forall u \in V$, 有 $\left| \frac{1}{n_u} - \frac{1}{\hat{n}_u} \right| \leq \epsilon/2$, 即 $|C - \hat{C}| \leq \frac{\epsilon n}{2}$.

问题2：连通分量的数目

10

$$\text{估计 } C = \sum_{u \in V} \frac{1}{n_u} \Rightarrow \text{估计 } \frac{1}{n_u} \Rightarrow \text{估计 } \sum_{u \in V} \frac{1}{n_u}$$

$$\hat{n}_u = \min \left\{ n_u, \frac{2}{\epsilon} \right\} \quad \hat{C} = \sum_{u \in V} \frac{1}{\hat{n}_u}$$

计算 \hat{n}_u 算法

1. 从 u 开始做先广遍历 (BFS) ;
2. while BFS 访问过的节点数量 $\leq \frac{2}{\epsilon}$ do
3. 继续做 BFS 遍历;
4. if 没有新节点 then 运行时间: $O(d \cdot 1/\epsilon)$
5. return BFS 访问过的节点数量;
6. return $2/\epsilon$;

问题2：连通分量的数目

11

$$\text{估计 } C = \sum_{u \in V} \frac{1}{n_u} \Rightarrow \text{估计 } \frac{1}{n_u} \Rightarrow \text{估计 } \sum_{u \in V} \frac{1}{n_u}$$

$$\hat{n}_u = \min \left\{ n_u, \frac{2}{\epsilon} \right\} \quad \hat{C} = \sum_{u \in V} \frac{1}{\hat{n}_u}$$

亚线性连通分量数目求解算法 (用 \hat{C} 估计 \hat{C})

1. $r \leftarrow b/\epsilon^2$;
2. 随机从 V 中选取 $U = \{u_1, \dots, u_r\}$;
3. 计算所有的 \hat{n}_{u_i} ;
4. return $\tilde{C} = \frac{n}{r} \sum_{u_i \in U} \frac{1}{\hat{n}_{u_i}}$;

运行时间: $O(d \cdot \frac{1}{\epsilon} \cdot \frac{1}{\epsilon^2}) = O(\frac{d}{\epsilon^3}) = o(|G|)$

问题2：连通分量的数目

12

$$\text{估计 } C = \sum_{u \in V} \frac{1}{n_u} \Rightarrow \text{估计 } \frac{1}{n_u} \Rightarrow \text{估计 } \sum_{u \in V} \frac{1}{n_u}$$

$$\hat{n}_u = \min \left\{ n_u, \frac{2}{\epsilon} \right\} \quad \hat{C} = \sum_{u \in V} \frac{1}{\hat{n}_u}$$

亚线性连通分量数目求解算法 (用 \hat{C} 估计 \hat{C})

1. $r \leftarrow b/\epsilon^2$;
2. 随机从 V 中选取 $U = \{u_1, \dots, u_r\}$;
3. 计算所有的 \hat{n}_{u_i} ;
4. return $\tilde{C} = \frac{n}{r} \sum_{u_i \in U} \frac{1}{\hat{n}_{u_i}}$;

近似性能: $r = O(\frac{1}{\epsilon^2} \log \frac{1}{\delta}) \Rightarrow \Pr[|\tilde{C} - C| \geq \epsilon n] \leq \delta$

定理[Chernoff/Hoeffding Bound]

X_1, X_2, \dots, X_n 为独立随机变量, 取值范围 $\in [0, 1]$, $\mu = \mathbb{E}[\sum_i X_i]$, 对任意 $t \geq 0$

$$\Pr[\sum_{i=1}^n X_i - \mu \geq t] \leq e^{-\frac{2t^2}{n}}$$

$$\Pr[\sum_{i=1}^n X_i - \mu \leq -t] \leq e^{-\frac{2t^2}{n}}$$

$$\Pr[|\sum_{i=1}^n X_i - \mu| \geq t] \leq 2e^{-\frac{2t^2}{n}}$$

13

问题3：近似最小支撑树

最小支撑树 (Min Spanning Tree)

输入: $G = (V, E)$, ϵ , $d = \deg(G)$
图G用邻接链表表示
边(u, v)的权重是 $w_{uv} \in \{1, 2, \dots, w\} \cup \{\infty\}$

输出: \hat{M} , 令 M 为 $\min_{T \text{ spans } G} W(T)$
 $(1 - \epsilon)M \leq \hat{M} \leq (1 + \epsilon)M$

MST问题可以在多项式时间求解, 例如Kruskal算法

14

问题3：近似最小支撑树

我们需要重新利用分解的方式定义 M

$$G^{(i)} = (V, E^{(i)})$$
, 这里 $E^{(i)} = \{(u, v) | w_{uv} \leq i\}$
 $C^{(i)} = \#CC \text{ in } G^{(i)}$

考虑两个例子

- $w = 1$: 只有权重为1的边, 且连通
 $M = n - 1$
- $w = 2$: 有权重为1和2的边, 且连通
 $M = n - 1 + C^{(1)} - 1 = n - 2 + C^{(1)}$

15

问题3：近似最小支撑树

定理 $M = n - w + \sum_{i=1}^{w-1} C^{(i)}$

α_i : 任一MST中权重为 i 的边的数目

$$\sum_{i>l} \alpha_i = C^{(l)} - 1$$

$$M = \sum_{i=1}^w i \cdot \alpha_i = \sum_{i=1}^w \alpha_i + \sum_{i=2}^w \alpha_i + \dots + \sum_{i=w}^w \alpha_i$$

$$= C^{(0)} - 1 + C^{(1)} - 1 + \dots + C^{(w-1)} - 1$$

$$= n - 1 + C^{(1)} - 1 + \dots + C^{(w-1)}$$

$$= n - w + \sum_{i=1}^{w-1} C^{(i)}$$

16

问题3：近似最小支撑树

利用连通分量数目估计的算法来估计MST大小

$$\tilde{O}\left(\frac{d}{\epsilon^3}\right) \Rightarrow \Pr[|\mathcal{C} - \tilde{\mathcal{C}}| \leq \epsilon n] \geq 1 - \delta$$

亚线性近似最小支撑树算法 (计算 \hat{M})

```

1. for i = 1 to w - 1 do
2.    $\tilde{C}^{(i)} = \text{approx. } \#CC \text{ of } G^{(i)}$  within  $(\epsilon' = \frac{\epsilon}{2w}) \cdot n$ ;
   with probability  $\geq 1 - \delta' = 1 - \frac{\delta}{w}$ 
3. return  $\hat{M} = n - w + \sum_{i=1}^{w-1} \tilde{C}^{(i)}$ ;

```

单次时间: $\tilde{O}\left(d \cdot \frac{1}{\epsilon'^3}\right) = \tilde{O}\left(\frac{dw^3}{\epsilon^3}\right)$
共计时间: $\tilde{O}\left(\frac{dw^4}{\epsilon^3}\right) = o(|G|)$
近似性能: $\Pr[|\hat{M} - M| \geq \epsilon M] \leq \delta$

17

问题4：Vertex Cover

顶点覆盖 (Vertex Cover)

输入: $G = (V, E)$ 、最大度数 d , 图G用邻接链表表示
 $C \subseteq V$ 是一个VC (Vertex Cover) 当且仅当
 $\forall (u, v) \in E$ 有 $u \in C$ 或者 $v \in C$

输出: 最小VC的大小 $|VC|$

- $|VC| \geq \frac{|E|}{d}$
- NP-完全问题
- 存在集中式的2近似算法

18

问题4: Vertex Cover

19

在亚线性时间内，能有多好的近似算法？

- ▶ 乘性的近似比 ($\frac{VC}{VC}$): No

0条边的图 $\Rightarrow |VC| = 0$; 1条边的图 $\Rightarrow |VC| = 1$

区分上述两种情况需要 $\Omega(n)$ 时间

- ▶ 加性的近似比 ($|\widehat{VC}| - |VC|$): Hard

- ▶ 乘性近似比的下界是 1.36, 很可能是 2

定义 [(α, ϵ) -近似] 对于最优解是 y 的最小化问题, 如果
 $y \leq \hat{y} \leq \alpha y + \epsilon$
 则称 \hat{y} 是该问题的 (α, ϵ) -近似。

问题4: Vertex Cover

20

设计想法: 利用分布式算法设计亚线性算法

分布式网络

- ▶ 最大度数 d
- ▶ 每个节点是一个处理器, 知道它的邻居是谁
- ▶ 同步计算、通信

每一轮 (同步)

- ▶ 每个节点计算基于它的输入、随机生成位、通信中收到的信息
- ▶ 向每个邻居节点发送消息
- ▶ 从每个邻居节点收取消息

问题4: Vertex Cover

21

设计想法: 利用分布式算法设计亚线性算法

分布式顶点覆盖 (Vertex Cover) 问题

- ▶ 输入: 网络图即是计算顶点覆盖的图 G
- ▶ 输出: 每个节点知道自己是否属于 VC

Fast Distributed Alg. \Rightarrow SubLinear Time Alg.

- ▶ k 轮分布式算法中, 节点 v 最多依赖于距离为 k 的节点, 至多 d^k 个

- ▶ 集中式算法可以在 d^k 时间内, 模拟分布式算法, 计算 v 是否属于 VC

如果是随机算法, 需要知道所有 d^k 个节点的随机位

问题4: Vertex Cover

22

- ▶ 存在 fast VC distribute alg (local distributed alg)?

- ▶ 如何利用分布式算法设计亚线性算法?

顶点覆盖的亚线性算法

1. 独立均等地从 G 中选取 $s = \frac{8}{\epsilon^2}$ 个节点构成 S ;
2. 为每个 $v \in S$, 构造 k 步邻居导出的子图 $G_k(v)$;
3. 为每个 $v \in S$, 在 $G_k(v)$ 上模拟分布式算法 D;
4. 如果 D 返回 v 为覆盖节点之一, $X_v = 1$;
5. return $|\widehat{VC}| = \frac{n}{s} \cdot \sum_{v \in S} X_v + \frac{\epsilon}{2} n$;

运行时间分析: $O(s \cdot d^k) = O(\frac{d^k}{\epsilon^2})$

问题4: Vertex Cover

23

- ▶ 存在 fast VC distribute alg (local distributed alg)?

分布式顶点覆盖算法 D

1. $\widehat{VC} \leftarrow \emptyset$;
2. **for** $i = 1$ to $\log d$ **do**
3. $\Delta \leftarrow \{v: v \notin \widehat{VC}, \deg(v) \geq d/2^i\}$;
4. $\widehat{VC} \leftarrow \widehat{VC} \cup \Delta$;
5. 从 G 中删除所有与 Δ 邻接的边;
6. **return** \widehat{VC} ;

- ▶ 运行时间: $d^{O(\log d)}$; 近似比: $(O(\log d), \epsilon n)$

大数据平台的并行算法

24